

Prvá ukážka R

Ako chutí R

Kým začnete písať R, urobíme niečo jednoduché, aby ste mali predstavu, kade povedú naše ďalšie kroky.

R notebook

Nachádzame sa v R-Markdown notebooku. Notebook pozostáva:

- z YAML hlavičky, ktorá obsahuje základné informácie o dokumente a jeho spracovaní
- z textu, ako je tento, s Markdown formátovaním
- z blokov kódu, ohraničených tromi *backtickmi*. *Backtick* je opačný apostrof a na klávesnici sa spravidla nachádza na klávese `~/`; vľavo hore pod `Esc`. *Nie je to apostrof!*
- z blokov výstupu, obsahujúcich textový a grafický výstup kódu z predchádzajúceho poľa.

Tento notebook je iný ako Google Colab notebook, s ktorým ste sa stretli na minulej hodine.

Predovšetkým musíte mať vlastnú inštaláciu R a R studia na svojom počítači. S Google Colab notebookom ste používali inštaláciu R na serveroch Googlu a vašim vývojovým protredím bola Javascriptová aplikácia, bežiaca vo vašom prehliadači.


Pre podrobnejšie informácie o organizácii RMarkdown notebooku si môžete pozrieť napríklad tento RMarkdown guide na stránkach R-Studia.

Pre všeobecný úvod do markdownu odporúčam návody na GitHubu, hlavne Mastering Markdown

V Google Colab notebooku ste mali textové bunky, tu vidíte skôr markdown, v ktorom sa nachádzajú bunky s kódom. Markdown v textových bunkách sa rendroval hneď po opustení bunky, zatiaľčo RMarkdown notebook musíte rendrovať naraz kliknutím na **Preview** alebo **Knit** na hornom paneli okna (alebo stlačením **Ctrl-Shift-K**). Môžete nastaviť, kde sa má zobrazíť vyrendrovaný dokument a či to má byť html, pdf alebo Word.

Podme študovať kód v našom notebooku, napríklad tuto máme prvú bunku:

```
plot(cars)
```



Kód v poli vykonáme stlačením **Ctrl-Shift-Enter** alebo kliknutím na zelený trojuholníček (*Run current chunk*) vpravo hore v poli kódu.

Ukážkové dátové súbory v R

Zjavne sme niečo nakreslili, ale čo je `cars`?

Je to ukážkový dátový súbor, ktorý máte k dispozícii spolu so základnými balíčkami v každej inštalácii R.

Recept Keď v R niečo stretnem a neviem čo to je, prvá vec, ktorú skúsím, je `help(cars)`, **Ctrl-Enter** pre spustenie, a kuk doprava, kde sa zobrazil panel s vysvetlením.

Aha, takže mám výsledky merania brzdné dráhy v závislosti od počiatočnej rýchlosti vozidla spred 100 rokov. Všimnite si, ako `help` dokumentuje obsah polí.

Parametre kódových polí

Ešte sme sa tiež naučili, ako vyzerá blok kódu v RMarkdown notebooku:

```
```{r}
plot(cars)
```
```

Poznámka: V zdrojovom mardownne tejto časti môžete vidieť čudné štruktúry so štyrmi backtickmi. Nemusíte si ich všimnúť - nie sú na výstupe vidieť, a slúžia mi len na zobrazenie bloku kódu v texte - teda na zabezpečenie, aby sa táto časť kódu nevykonala, iba zobrazila.

Úloha: Vytvorte takýto blok kódu a vykonajte ho.

```
```{r echo=FALSE}  
plot(cars)
```
```

Parametrov kódového bloku je viac a môžete nimi riadiť vykonávanie kódu.

- * `include = FALSE` zabráni, aby sa kód alebo výsledky objavili vo výslednom súbore. R Markdown ale vykoná kód.
- * `echo = FALSE` zabráni, aby sa kód objavil vo výslednom súbore, zobrazia sa ale výsledky. Takto môžete zabrániť zobrazeniu kódu.
- * `message = FALSE` zabráni zobrazovaniu správ, generovaných kódom, vo výslednom dokumente.
- * `warning = FALSE` zabráni zobrazovaniu varovaní, generovaných kódom, vo výslednom dokumente.
- * `fig.cap = "..."` pridá legendu k vytvorenému obrázku (hodí sa iba pre určité účely)

V dokumentácii k RMarkdownu nájdete ďalšie možnosti.

Podme sa teda pozrieť, ako vyzerajú dáta `cars`.

```
head(cars)
```

```
##      speed dist  
## 1         4    2  
## 2         4   10  
## 3         7    4  
## 4         7   22  
## 5         8   16  
## 6         9   10
```

`head` zobrazí iba niekoľko prvých riadkov tabuľky. Používame automaticky preto, lebo keby ste mali veľké dáta, mohol by sa váš počítač na dlhú chvíľu zamyslieť, kým by vám na displeji vyroloval 2 gigabajty čísel. Bežne chceme vidieť hlavičku a pár prvých riadkov.

Úloha Toto je malý dátový súbor a tak si môžete zobrazíť všetky dáta. Vytvorte blok kódu s jediným príkazom `cars` a vykonajte ho.

```
cars
```

```
##      speed dist  
## 1         4    2  
## 2         4   10  
## 3         7    4  
## 4         7   22  
## 5         8   16  
## 6         9   10  
## 7        10   18  
## 8        10   26  
## 9        10   34  
## 10       11   17  
## 11       11   28  
## 12       12   14  
## 13       12   20  
## 14       12   24  
## 15       12   28  
## 16       13   26  
## 17       13   34  
## 18       13   34  
## 19       13   46  
## 20       14   26  
## 21       14   36  
## 22       14   60
```

```
## 23    14    80
## 24    15    20
## 25    15    26
## 26    15    54
## 27    16    32
## 28    16    40
## 29    17    32
## 30    17    40
## 31    17    50
## 32    18    42
## 33    18    56
## 34    18    76
## 35    18    84
## 36    19    36
## 37    19    46
## 38    19    68
## 39    20    32
## 40    20    48
## 41    20    52
## 42    20    56
## 43    20    64
## 44    22    66
## 45    23    54
## 46    24    70
## 47    24    92
## 48    24    93
## 49    24   120
## 50    25    85
```

R data frame

Vidíme tabuľku, ľahko zistíme, že má 50 riadkov a 2 stĺpce.


- Stĺpec úplne vľavo sa nepočíta, nemá meno a budeme ho nazývať *index*. Automaticky ho vytvorilo R a slúži na jednoznačné označenie riadkov v tabuľke. * *Riadky* zodpovedajú jednotlivým prípadom, pacientom, vzorkám a pod.
- *Stĺpce* zodpovedajú vlastnostiam prípadov, pacientov, vzoriek.

Toto je typický spôsob usporiadania dát pre štatistickú analýzu (nielen v R) a vynaložíme pomerne veľa času, aby sme sa naučili svoje dáta takto usporiadať.

Aká to je závislosť?

Tak máme nejaké dáta, a čo to je za závislosť?

```
plot(cars)
```



Úloha:: Ako uložíme obrázok do súboru? (Nápoved: Spýtajte sa Googlu)

```
png("CarPlot.png")
plot(cars)
dev.off()
```


```
## pdf
## 2
```

Tip: Ak sa notebook začne chovať čudne, vždy pomôže **Session -> Restart R**, pričom si môžete vybrať, čo sa má stať po reštarte.

Podme to nakresliť poriadne.

```
plot(cars, xlab = "Speed [mph]", ylab = "Stopping distance [ft]", las = 1)
lines(lowess(cars$speed, cars$dist, f = 2/3, iter = 3), col = "red")
title(main="Stopping distance vs. initial speed")
```

Stopping distance vs. initial speed




Úloha: Kto netuší, čo je *lowess*, čo spraví?

Recept: stĺpce dátovej tabuľky sú `data$<meno_stĺpca>`

Naša závislosť vyzerá ako parabola, tak si ju nakreslíme v logaritmickej škále:

```
plot(cars, xlab = "Speed [mph]", ylab = "Stopping distance [ft]", las = 1, log = "xy")
lines(lowess(cars$speed, cars$dist, f = 2/3, iter = 3), col = "red")
title(main="Stopping distance vs. initial speed, log-log scale")
```


Stopping distance vs. initial speed, log-log scale



Úloha: Funguje slovenská diakritika? Skúste poslovenčiť popisy v grafe.

```
plot(cars, xlab = "Počiatková rýchlosť [mile / hod]", ylab = "Brzdná dráha [stopy]", las = 1,  
lines(lowess(cars$speed, cars$dist, f = 2/3, iter = 3), col = "red")  
title(main="Brzdná dráha v závislosti od počiatkovej rýchlosti, log-log škála")
```

Brzdňá dráha v závislosti od pociatocnej rýchlosti, log-log škála



Diakritika funguje inline v notebooku, ale nie vo vyrendrovanom dokumente. To teraz nejdeme riešiť.

- Rýchle riešenie je nahradiť znaky, ktoré sa zle zobrazujú, ich kódmi Unicode. Napríklad v našom prípade namiesto znaku “č” treba vložiť , a problém je vyriešený, podobne možno nahradiť iné problematické znaky.
- Ako vidíte, normálny text sa rendruje správne, takže problém sa väčšinou týka niekoľko málo znakov.
- Je tiež možné doladiť nastavenia kódovania a fontov v RStudiu, aby sa problémy vyriešili, ale nejdem s tým strácať čas. Tento problém balíka `knitr` je známy a kým sa R naučíte, najskôr nebude existovať.

Tu už naša závislosť vyzerá ako priamka, tak to skúsme fitnúť.

POZOR začína štatistika!

```
fmL <- lm(log(dist) ~ log(speed), data = cars)
summary(fmL)

##
## Call:
## lm(formula = log(dist) ~ log(speed), data = cars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.00215 -0.24578 -0.02898  0.20717  0.88289
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.7297     0.3758  -1.941   0.0581 .
## log(speed)    1.6024     0.1395  11.484 2.26e-15 ***
```


šipku na levém okraji bloku.

úbo







Figure 1: Kódy Unicode najdeme napríklad pomocou Character Map


```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4053 on 48 degrees of freedom
## Multiple R-squared:  0.7331, Adjusted R-squared:  0.7276
## F-statistic: 131.9 on 1 and 48 DF,  p-value: 2.259e-15
```

```
plot(fmL)
```









Máme tu kopu výstupov.

Z textového výstupu vidíme, že máme celkom dobrý model $d = e^{-0.73}v^{1.6}$

Tip Ešte vidíme, že môžeme písať aj vzorce v TeX-ovej notácii, buď do riadku, napríklad $\sigma^2 = E(X^2) - E(X)^2$ alebo samostatne, napríklad

$$\chi^2(\mathbf{z}) = \frac{1}{n} \sum_{i=1}^n z_i^2$$

Výsledkom nášho programovacieho úsilia môže byť report, ktorý zobrazíme záverečným kliknutím na **Preview** alebo **Knit** (alebo **Ctrl-Shift-K**). Markdown nám umožňuje jednak vyrenderovať náš dokument do niekoľkých formátov, ale aj použitím príslušných tém vytvoriť napríklad slajdy či brožúru.

Systém práce v RStudiu je dvojfázový:

- Najprv postupne píšem dokument a po krokoch odladím kód, aby počítal, čo treba.
- Nakoniec dokument vyrendrujem do požadovanej výslednej podoby.

Úloha: Vyhľadajte si na Googli všetko, čomu nerozumiete. Alebo sa spýtajte.

Úloha: Čo keby som vo výstupe nechcel R-kód?

Úloha: Skúste svoj report vyrenderovať do pdf.